

SISTEMA INTELIGENTE DE CLASSIFICAÇÃO DE DEFEITOS EM CHAPAS DE AÇO

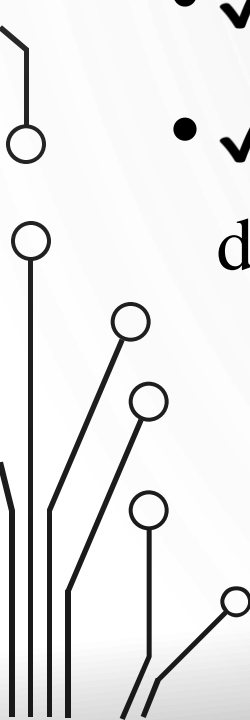

**Projeto Final – Bootcamp de Ciência
de Dados e IA**

PAULO FRANCISCO NGINGA GASPAR | 15/05/2025





INTRODUÇÃO AO PROBLEMA

- ✓ A indústria siderúrgica exige controle de qualidade rígido.
 - ✓ Chapas defeituosas impactam segurança e custo.
 - ✓ Objetivo: automatizar a detecção e classificação de defeitos em aço.
- 
- 

ENTENDIMENTO DOS DADOS

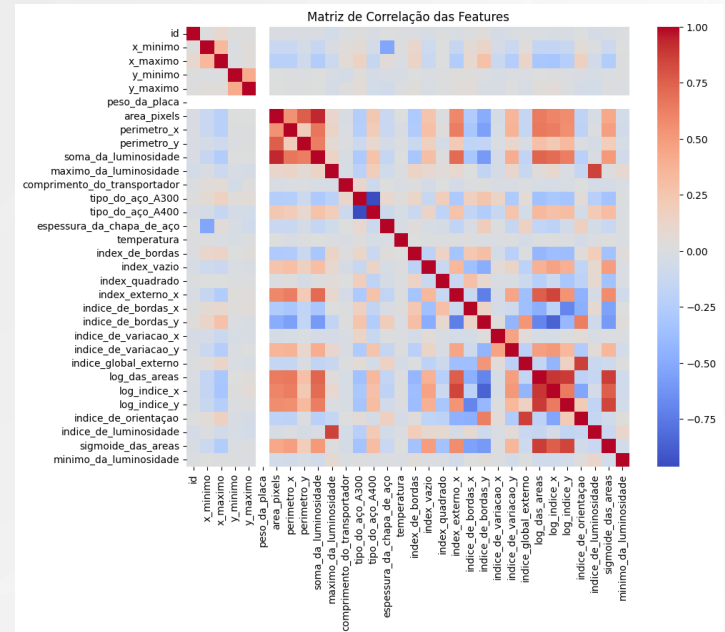



Gráfico de distribuição de classes e matriz de correlação.

- ✓ 31 variáveis numéricas e binárias.
- ✓ Classes: 6 falhas específicas + 1 genérica.

PREPARAÇÃO DOS DADOS

- ✓ Conversão binária de colunas (tipo_do_aço).
- ✓ Imputação de valores ausentes (moda e mediana).
- ✓ Filtro de linhas com uma única falha para problema multiclasse.

MODELAGEM PREDITIVA

- ✓ Modelos: Random Forest e XGBoost.
- ✓ Balanceamento com SMOTE.
- ✓ Otimização de hiperparâmetros com GridSearchCV.

IMPORTÂNCIA DAS FEATURES E PCA







Gráfico de importância e PCA colorido.

- ✓ Features mais importantes: área, perímetro, brilho.
- ✓ PCA mostra separabilidade entre classes.


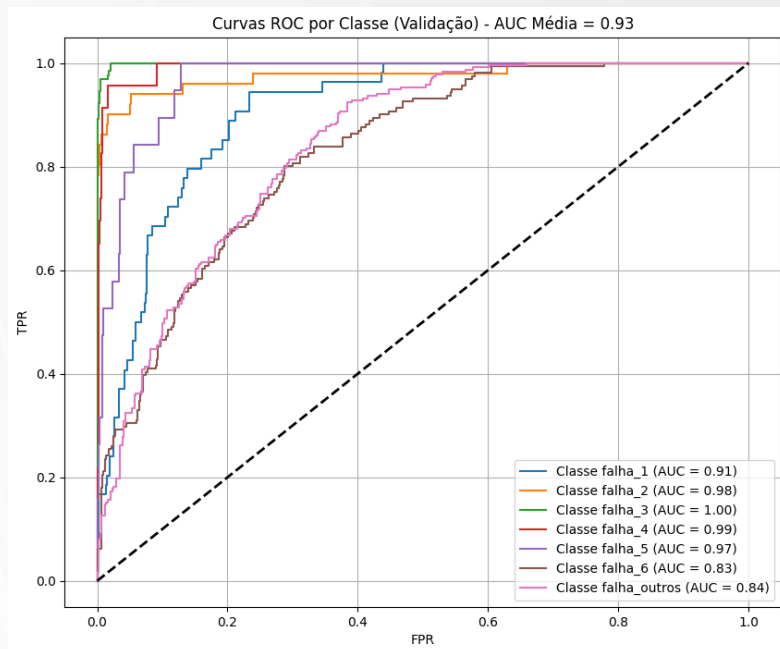
AVALIAÇÃO DOS MODELOS



Curva de aprendizado e matriz de confusão.

- ✓ Melhor F1 RF: 0.664 | Melhor F1 XGB: 0.674
- ✓ XGBoost teve melhor generalização e performance.
- ✓ Identificação de overfitting (F1 Treino: 1.0000 | F1 Validação: 0.6875)

AVALIAÇÃO DOS MODELOS



Curvas ROC por Classe (Validação) - AUC Média e AUC por Classe.

CONCLUSÕES

- **✓ Modelo final: XGBoost**
- **✓ F1-macro média: 0.674 (validação cruzada)**
- **✓ Modelo pronto para uso com novos dados.**

PRÓXIMOS PASSOS (EXTRAS)

- ✓ API com FastAPI para integração.
- ✓ Dashboard com Streamlit para análise interativa.
- ✓ Containerização com Docker.



AGRADECIMENTOS E CONTATO

- ✓ Obrigado pela atenção!
 - ✓ Código disponível no GitHub.
- 
- 